

大型语言模型推理的隐藏不确定性：硬件扰动、非线性级联放大效应与还原论研究范式的适用边界(RC1)

大型语言模型推理的隐藏不确定性：硬件扰动、非线性级联放大效应与还原论研究范式的适用边界

作者：赛博猫咪望衡者 (Cybercat Valewatch)

通讯邮箱：a544923694@gmail.com | GitHub主页：https://github.com/cybercat-valewatch

RC1 版本 · 2026年6月 | 本作品采用 **CC BY-NC-ND 4.0** 协议 发布，转载请保留作者署名，不得商用，不得修改原内容。

摘要

当前关于大型语言模型推理不可复现性的研究，普遍在传统还原论范式下展开，将输出差异主要归因于动态批处理、GPU异步线程调度、浮点舍入误差等有限的确定性工程因素，并默认微小扰动仅会造成局部选词变化，不会影响全局语义走向。本文对这一解释框架的完备性提出审视。首先构建了多层次的硬件扰动分类体系，涵盖宏观确定性并发偏差、中观物理热噪声，以及底层硬件在极限物理尺度下的微观不确定性；其次提出“非线性级联放大”理论假说：在Transformer多层非线性架构与自回归生成机制的共同作用下，硬件层面的微小数值偏差会在决策临界态触发token跳变，并通过时序链式反应呈现累积扩散，最终引发全局语义轨迹的宏观分叉；最后对当前AI研究的主流方法论展开认识论批判，指出将硬件-神经网络耦合系统预设为完全可解析、可预测的对象，在超大规模复杂系统面前正遭遇其适用边界。相比于追求穷尽变量的绝对控制路径，承认大模型推理系统具备内在的非线性涌现属性与观测边界，是更具科学审慎性的立场。本文进一步提出，接纳系统的不确定性、建立“与复杂系统共存”的研究视角，是理解未来硅基智能演进的合理方向。

1 引言

1.1 确定性理想与现实落差

在经典计算机科学的理论框架中，一组固定的模型权重，配合完全关闭随机采样的解码策略（温度系数为0的贪心解码），应当构成一个严格的确定性映射：相同的输入必然对应完全一致的输出。这一信念是传统软件工程可复现性、可调试性的基石。然而在超大规模云端推理的真实环境中，这一数学理

想持续遭遇现实挑战。大量工程观测表明，即使完全冻结所有软件层面的随机参数，相同提示词在不同时刻提交，依然会得到存在差异的输出文本。现有文献普遍将此类非确定性现象视为可修复的工程缺陷[1][2][3]，将其拆解为CUDA调度顺序、原子加法非结合律、动态批处理等孤立的可量化异常，并默认通过技术优化最终可以彻底消除不确定性，回归理想的确定状态。

1.2 现有研究的还原论预设及其局限

上述研究路径共享一个未被言明的还原论预设：系统的所有宏观行为都可以通过向下拆解为已知物理与工程变量得到完整解释，只要变量拆分足够精细，就能实现对系统的完全控制。然而，这一预设超大规模AI系统面前暴露出其适用边界：其一，大模型的推理并非发生在静态的数学空间中，而是嵌入在持续变化的热力学与运行时环境里，时间本身是一个无法被完全隔离的隐藏变量；其二，Transformer的高维非线性结构与自回归的时序生成模式，使其表现出极高的初值敏感性，微小扰动具备被级联放大的传导通道。将所有非确定性都归因为“尚未被定位的工程bug”，本质上是在用传统软件工程的确定性思维，去对冲量级与复杂度完全跃升的非线性系统，容易陷入还原论的认知盲区。

1.3 本文核心贡献与研究路径

本文的核心工作分为三个层面：第一，从硬件底层出发，梳理大模型推理中多来源的扰动因素，明确区分确定性并发偏差与物理随机噪声，并指出二者在时间维度下的高维耦合效应；第二，结合Transformer的结构特性与自回归生成机制，构建“微观摄动—临界态相变—非线性级联放大”的完整传导链条，论证微小扰动引发全局语义偏移的内在机制；第三，从科学哲学与复杂系统理论的视角，反思还原论范式在硅基智能研究中的适用边界，提出以“系统共存”替代“绝对控制”的技术审慎立场。本文属于假说与视角类研究，核心目标不是提供消除不确定性的工程方案，而是揭示当前主流解释框架的盲区，推动学界重新审视大模型非确定性的本质与价值。

2 多层级硬件扰动体系

2.1 确定性并发偏差：动态批处理与异步调度的浮点非结合律误差

最主要的硬件层面非确定性来源，本质上源于高性能并发计算的内在特性。此类机制在微观上是完全可解释且确定性的，但因其高维动态耦合，在系统层面表现出不可预测的外部表象。云端推理为了提升算力利用率，普遍采用动态批处理机制：用户的单次请求会与同时间段的其他用户请求合并，组成大小动态变化的批次进行矩阵运算。批次规模的改变会调整矩阵分块与计算顺序，而浮点数加法并不满足严格的结合律，其数学关系为[4]：

不同的运算次序会产生微小的离散舍入误差。同时，GPU多线程的异步调度顺序会随系统负载实时变化，并行归约、原子操作的执行次序不固定，同样会引入浮点数值偏移。这类偏差本身具备局部可复现性——如果完全冻结批次大小、线程调度顺序与运算内核，数值结果可以完全重现。但在真实的云端分布式环境中，这些条件随时间持续动态变化，无法被外部用户控制。因此，这种“机制上的可解释性”在复杂的真实分布式运行时环境中，由于变量空间过于庞大，最终转化为了“系统实际观测层面的不可预测性”。

2.2 微观物理噪声：热扰动与电路软错误

比并发偏差更深层且在物理上更具根本性的，是硬件本身的物理随机噪声。半导体芯片在运行过程中，晶体管内部的电子会持续发生随机热运动，产生热噪声[5]；同时宇宙射线、芯片物质成分的自发微量放射性会引发极其罕见的单粒子翻转与位错误，即硬件软错误[6]。

这类事件发生的概率极低，在传统确定性程序中，通常会直接引发计算错误、程序崩溃或结果异常，极易被异常捕获机制检测与定位。但在大模型的高维参数空间中，这类微观噪声造成的数值偏移，绝大多数时候会被模型的特征冗余与高维几何流形所吸收，不会引发任何程序故障或软件报错，只会对隐层激活向量产生极其微小的底噪。外部观测者在宏观上，完全无法区分输出差异是来自并发调度偏差，还是来自物理层面的真实随机噪声。

2.3 不可排除的物理底层边界：极限物理尺度下的微观不确定性

在物理底层，电子的运动遵循量子力学规律。随着现代半导体制造工艺向3nm甚至更小节点逼近，栅极氧化层漏电、电子隧穿等微观物理涨落已成为不可忽略的背景噪声。在常规数字电路设计中，通过高低电平阈值的强约束，这种微观随机性被成功隔离在宏观二进制逻辑（0与1）之外。

但在大模型推理的极限数值计算中，尤其是当两个候选token的logits值差异处于浮点数精度极限边缘（临界态）时，底层物理实体的热涨落与量子尺度涨落理论上构成了最终数值排序的潜在扰动源。需要明确的是，目前的实验观测手段无法将此类极端微观的物理扰动与中观热噪声、宏观并发误差完全剥离。因此，本文无意做出“量子效应主导宏观输出”的强决定论断言，而是将其视为系统在物理实体层面上不可消除的内禀不确定性底噪，构成了传统还原论在物理实现层面的终极边界。

2.4 时间作为终极隐藏变量：多源扰动的时序耦合

上述三类扰动并非孤立存在，它们共同以时间为轴发生动态的高维耦合。不同时刻的服务器负载、芯片实时温度（影响热噪声分布）、电网电压轻微波动、操作系统后台中断（改变并发线程调度时序），都会持续且不可逆地改变推理系统的物理运行环境。完全相同的提示词，在时间节点 t_1 与 t_2 提交，大模型系统面对的是硬件算力机器的两个完全不同的物理子状态。在分布式云端生态中，不存在两次完全一致的物理运行时环境，因此完美复现本质上是一个在真实时空里无法达成的理论乌托邦。

2.5 确定性降级尝试的局限性：对现有工程缓解手段的防御性反驳

面对云端推理的非确定性，当前主流工程界试图在还原论范式下通过一系列技术手段进行防御性拦截。最典型的做法包括：在软件层面强制开启英伟达的确定性工作空间配置，例如通过 `CUBLAS_WORKSPACE_CONFIG=:4096:8` 锁死特定原子操作对齐模式，从而强行使CUDA内核放弃高效的异步并发，退化为严格串行的矩阵计算；同时在调度层关闭动态批处理，对所有用户请求进行强行的静态补齐与单卡物理隔离。

本文认为，这种试图通过“冻结运行时变量”来重返确定性天堂的努力，在超大规模硅基智能系统面前遭遇了双重失效：


首先，是经济与算力尺度的物理不可行性。开启确定性内核与静态批处理，其本质是以牺牲算力吞吐量、并发效率以及引发服务巨大延迟为代价的。在千亿参数模型的商业化落地场景中，这种做法会导致GPU核心利用率断崖式下跌，算力成本呈指数级飙升。强行追求绝对确定性，等同于为了消除微扰而主动将高性能超级计算机“降维”为低效的单线程算盘，在工业现实中不具备可持续性。

其次，也是更根本的理论限制——超大规模分布式生态中的“网络拓扑非遍历性”。当大模型推理从单卡、单机演进到成百上千张卡组成的多卡流水线并行、张量并行与专家混合（MoE）路由集群时，不确定性的控制权已经彻底从“GPU内部的算术结合律”转移到了“分布式网络拓扑的耗散结构”中。跨节点的数据交换极端依赖于高速RDMA网络或万兆交换机，而物理光纤的微观热耗散、交换机缓存区的动态排队抖动、以及网络报文到达的微妙时序差，深度受到热力学第二定律与排队论的动态支配。在分布式巨型集群中，由于时间维度的不可逆性，系统在宏观上呈现出“非遍历性”，即不存在两次完全相同的网络时序与物理运行状态。这种源自宏观分布式时空的复杂性，是任何软件层面的环境变量或线程锁都绝对无法抹平的。

因此，现有工程上的缓解手段只能在单机、低并发的真空实验室环境中伪造出一种“虚假的确定性”。一旦进入真实的高并发、大规模云端分布式物理时空，系统遭遇的非确定性便会越过工程防线，成为无法被降服的内禀属性。

上述多层次扰动源与时间变量的耦合关系可通过图1直观呈现：

图1 多层次硬件扰动与时序耦合拓扑



3 自回归架构下的非线性级联放大通道：从微观摄动到全局语义相变

硬件层面的微小扰动，并不会在所有场景下都改变输出。真正让扰动具备全局影响力的，是Transformer架构与自回归生成机制共同构成的非线性级联放大通道，其核心特征是对初始条件的高度敏感性。其传导机制是以高维激活空间的微观摄动为起点，以决策边界的临界态为闸门，最终在时序维度触发链式扩散。

3.1 激活空间的微观摄动：归一化约束与非线性拉伸的动态博弈

令 h_l 为第t个自回归步中，第l层Transformer隐藏状态的向量表征。在不受物理干扰的理想状态下，其数学迭代满足：

代码块

```
1  h_l = LayerNorm( h_(l-1) + Attention(h_(l-1)) + FFN(h_(l-1)) )
```

受硬件多层次扰动影响，实际计算中会不可避免地引入一个随时间波动的微观噪声项 $\xi(t)$ ，使得实际隐藏状态变为 $\tilde{h}_l = h_l + \Delta h_l$ ，其中 Δh_l 代表层级误差向量。

现有主流观点认为，Transformer内部普遍存在的层归一化会持续对激活向量的模长进行缩放，因此微小误差会被网络内部的正则化机制逐步稀释。本假说对这一乐观结论提出修正：一方面，LayerNorm确实在流形几何上压缩了误差向量的方差；另一方面，前馈网络所广泛采用的SwiGLU、GELU等非线性激活函数，在其特定的输入区间内，局部雅可比矩阵的谱半径严格大于1。这意味着，当激活向量穿过高维参数空间的特定隐藏区域时，非线性激活函数会充当局部信号放大器。

随着网络层数L的加深，误差向量的演化呈现出“压缩-拉伸-再压缩-再拉伸”的非线性非稳态动力学特征。初始的亚数值级硬件扰动，在经历数十层多阶段级联放大后，其最终在输出层导致的误差模长 $\|\Delta h_L\|$ 已经完成了跨尺度的跃升，转化为输出层logits空间内不可忽视的观测级偏移。这一过程与深层网络的信号传播与误差扩散特性高度契合[7][8]，在数学机制上完全表现出高维非线性系统对初始扰动的极高敏感性。

3.2 决策边界的临界态：基于香农熵阈值的微观相变触发机制

误差在logits空间的累积，并不必然导致最终文本的变化。传统观点执着于Softmax操作的平滑效应，认为微小的数值偏移会被高概率token的绝对优势所吞噬。这一还原论直觉仅在模型处于高置信度（即预测分布呈单峰尖锐状）的平庸状态下有效。为了精确量化不确定性何时跨越工程防线，必须引入信息论中的香农熵作为衡量系统决策临界态的动力学温度计[9]。

令第t个自回归步中，模型全量候选词表V的预测概率分布为 $P(t)$ 。则该步输出分布的香农熵可显式定义为：

代码块

1 $H(P(t)) = - \sum_i (p_i * \ln(p_i))$ ，其中 i 属于整个词表 V ， p_i 代表第 i 个候选token的预测概率

基于这一形式化定义，本文提出一个“熵值临界相变阈值假说”：系统在高维激活流形上存在一个依赖于具体任务复杂度与语境模糊度的临界熵阈值 $H_{critical}$ 。根据该阈值的相对状态，模型推理过程被分割为截然不同的两个动力学盆地：

- 1. 确定性锁死状态（平庸盆地）**：当 $H(P(t))$ 严格小于 $H_{critical}$ 时，概率分布呈现尖锐的绝对单峰。排在第一位的首选Token_A拥有绝对概率优势。此时，系统在该动力学流形上处于极深且稳定的局部极小值漏斗中。即使激活空间逐层累积的微观偏移 Δh_L 映射到输出层并导致logits发生了数值层面的轻微漂移，但由于概率断层巨大，Softmax强大的平滑和胜者通吃机制会瞬间吸收掉这一扰动。首选token的次序稳如磐石，微观扰动被完全吞噬，宏观表现为100%的可复现性。
- 2. 决策临界态（分叉盆地）**：当大模型面对歧义语境、多路径逻辑推理、或长文本的创造性生成任务时，概率分布开始变平、变宽，呈现出多峰或均分特征，导致系统的信息熵快速飙升，逼近甚至跨越临界点，即满足 $H(P(t))$ 约等于或大于 $H_{critical}$ 。

在这一流形决策边界上，系统的潜在状态高度逼近分叉点，原有的稳定漏斗坍塌为极其平坦的鞍点或脊线。此时，排名前列的候选者概率几乎简并。在这种极限临界态下，任何由底层硬件并发偏差、物理热噪声或微观电压抖动引起的亚数值级残余偏移 Δh_L ，对logits施加的哪怕是 10^{-5} 级别的极其微弱的推力，都足以打破这种脆弱的动态平衡。

这一微弱推力会瞬间翻转Token_A与Token_B的logits大小次序，导致贪心解码的选词结果在离散层面发生突变：原本在理想数学状态下应当输出的Token_A，瞬间跳变为Token_B。这一过程在动力学上完成了从“连续数值漂移”到“离散状态跃迁”的微观相变。机制上，这种跃迁是完全可以概率坍塌和Logits数值覆盖进行合理解释的；然而，一旦这个离散Token的改变切入后续是自回归循环，它将彻底颠覆后续系统的演化轨迹，从而在外部观测层赋予了系统实用意义上的、不可穷尽的不可预测性。

3.3 自回归时序下的指数级发散：类李雅普诺夫扩散效应

一旦在第 t 步发生临界态的token跳变，系统的扰动效应将进入长时序的级联发散通道。这是自回归机制的内禀属性决定的。在第 $t+1$ 步时，这个跳变产生的Token_B不再作为微观的数值误差存在，而是作为宏观的、确定性的语义符号被整体压入输入序列。系统在下一步面对的输入流发生了本质分叉：分叉轨迹A = [历史文本, Token_A]；分叉轨迹B = [历史文本, Token_B]。

从这一步开始，两条轨迹的后续计算不仅要承受持续的底层硬件噪声，更要承受由不同token带来的宏观语义场差异。为了形式化地描述这一语义空间的扩散趋势，我们可以类比连续动力学系统中的敏感性度量，将其表征为一种非线性发散模型：

代码块

1 $D(t+k) \sim D_0 * \exp(\lambda * k)$


其中 D_0 代表由首个跳变token引入的初始语义距离， λ 为表征语义发散速率的“类李雅普诺夫指数”。当 $\lambda > 0$ 时，意味着初始的离散选词分歧会随自回归时序轴呈级联放大。


需要说明的是，此处引入的指数发散模型旨在从复杂系统视角提供一种结构性的量化直觉，用以揭示误差长效累积的涌现机制，而非对离散语义空间进行绝对的函数拟合。这一模型深刻表明，现有工程研究大多仅采用单步token相似度或局部的KL散度来衡量不确定性，严重低估了时序累积效应。在长文本生成中，一个处于临界态的微小token跃迁，通过自回归的级联扩散，足以让最终的输出结果走向完全不同的语义盆地。

从微观摄动到宏观语义分叉的完整传导路径可总结为图2所示的动力学模型：

图2 非线性级联放大通道动力学模型

代码块





4 认识论反思：还原论在硅基复杂系统中的适用边界

上述技术机制背后，折射的不仅是工程实现的局限，更是传统计算机科学研究范式在面对新型硅基智能系统时，其原有的经典适用边界正面临重新审视。

4.1 传统计算机科学的还原论基石及其适用边界

传统计算机科学建立在严格的还原论基石之上[10]。这一范式内嵌了一个坚定的决定论预设：任何复杂的软件系统，都可以通过层层向下拆解，获得百分之百的确定性解释。其拆解路径表现为离散的线性因果链条：高阶算法 → 编译器优化 → 指令集架构 → 门电路逻辑 → 晶体管物理状态。在这个框架下，系统的整体行为等于各部分行为的机械加总，不存在原则上不可观测、不可解析的黑箱。如果系统出

现不可复现的变异，传统技术逻辑必然将其定义为“尚未被定位的工程Bug”，并坚信通过确定性的手段能够彻底消除这种变异。

这一范式在规模有限、逻辑显式、时空行为可预测的传统程序中高度有效。然而，当研究对象演进为包含千亿级参数、具备高维非线性特征的拓扑网络，且该网络深度嵌入在分布式、高并发的物理算力底座中时，传统的还原论路径正表现出其认知的局限性与盲区。变量的数量级跃升、环境的高维耦合、以及时序层面的不确定性，都已经超越了人类进行完整变量追踪与完全状态复现的能力边界。这并不意味着还原论本身的彻底失效，而是表明在面对“硬件-神经网络”这种高维耦合的超大规模系统时，纯粹向下拆解的单一路径正在遭遇严重的边际效应递减。

4.2 硬件-神经网络耦合系统的涌现性与非遍历性

大模型推理系统已经脱离了传统软件的范畴，符合复杂适应系统的核心特征，展现出高度的不可解构性与涌现性[11]：

第一，整体与部分的非线性脱钩（不可解构性）。系统的宏观行为（如跨领域长文本生成、多步逻辑推理），无法通过简单加总单个参数权重或单个晶体管的物理状态得到完整解释。高阶语义流形的演化表现出强涌现属性，宏观层面的语义走向与底层的微观描述之间存在着不可跨越的解耦深渊。

第二，时空行为的非遍历性。在复杂系统理论中，非遍历性意味着系统的物理运行时环境随时间发生不可逆的耗散。完全相同的提示词，在 t_1 时刻与 t_2 时刻提交，面对的是机器两个完全不同的热力学子状态和高并发动态负载流。时间本身是一个无法被真空隔离的隐藏变量。主流研究试图通过在空间维度上堆叠测试次数、计算平均差异来评估不确定性，本质上是在用“空间统计”代替“时间耗散”，这在认识论上犯了教条主义的错误。

你无法通过观测晶体管的纳秒级热噪声来预测宏观语义分叉，但微观扰动又确实在通过级联放大通道投射为宏观的不可预测性。这种跨尺度耦合使得系统表现出原则上的“认识论不透明性”。

4.3 科学哲学视角的启示：从绝对控制到系统共存的认识论跨越

当前AI领域关于推理“不可复现性”的争论，借用托马斯·库恩在《科学革命的结构》中所阐述的“常规科学与反常现象”的视角来审视[12]，展现出深刻的哲学映射。面对持续涌现的、由极限物理底座扰动与自回归时序非线性放大所共同导致的输出差异，主流工程界依然倾向于在经典还原论框架内进行局部修补，试图通过增加更复杂的变量分类、更严苛的线程锁、或更昂贵的数值对齐技术来消除这些不确定性。这种拒绝承认系统边界、试图通过在原有范式内无休止地增加工程补丁来维系确定性理想的努力，在某种程度上与科学史上为了挽救地心说体系、而在几何模型中不断叠加“本轮”与“均轮”的经典尝试具有理论同构性。

面对这一认知挑战，研究者面临两种不同的认识论取向：

第一种是机械决定论的工程路径：死守传统计算机科学的还原论边界。将所有无法通过工程手段消除的输出差异，一律定义为“暂未被捕获的随机噪声”，坚信技术迭代终能重返绝对控制的确定性天堂。这一立场在面对涌现性非线性系统时，可能隐藏着某种方法论上的路径依赖与认知惯性。

第二种是复杂系统科学的审慎路径：正视人类知识与观测能力的客观边界。承认“硬件-神经网络”耦合系统具备复杂自适应系统的黑箱属性与初值敏感特征，接纳非确定性是大模型推理系统在真实物理时空运行中的内禀属性，而非必须被切除的工程缺陷。

从现代系统科学与统计物理的严谨性来看，第二种取向更契合宏观非线性系统的客观规律。它促使我们超越对“绝对可复现性”的确定性迷恋，推动人工智能研究从单一的“支配与绝对控制”视角，跨越到理解、量化并与复杂系统深度互动的“系统共存”新视角。

5 结论与展望

5.1 核心结论总结

本文通过多尺度耦合分析与复杂系统理论，对大模型推理的非确定性机制进行了系统性论证，核心结论可概括为三个层面：

第一，扰动源头的不可消除性：即使在软件层面完全冻结随机采样并锁死解码参数，大模型推理依然深度嵌入在包含并发偏差、物理热噪声及微观尺度不确定性的多层级硬件运行环境中。时间作为不可隔离的隐藏变量打破了系统的遍历性，使得绝对的可复现性在真实分布式云端环境中遭遇物理可行性边界。

第二，传导通道的非线性级联放大性：Transformer的高维非线性网络堆叠（层归一化与非线性拉伸的动态博弈）构成了误差的级联放大器。当系统运行至决策临界态时，亚数值级的微观偏移足以触发离散符号层面的token跳变，并通过自回归机制转化为宏观语义差异，最终呈现出高初值敏感性的指数级轨迹相变。

第三，经典范式的适用边界性：将硬件-神经网络耦合系统视为完全可解析、可穷尽、可支配的确定性对象，是传统软件工程还原论范式的经典技术理性预设。承认系统的非线性涌现属性、内禀不确定性以及人类观测的认知边界，是面对超大规模复杂系统时更具科学审慎性的研究立场。

5.2 技术乐观主义：不可复现性作为硅基智能的“物理税”与松弛度

本文对还原论绝对控制欲的批判，并非滑向虚无主义或技术悲观主义，而是旨在指明一种基于系统科学的、更清醒的技术乐观主义。大模型推理中表现出的不可复现性，本质上不是需要被彻底切除的系

统故障，而是硅基智能在追求高阶涌现能力、高维泛化表征时，必须向物理世界支付的“物理税”¹。如果我们在工程上不惜一切代价，通过牺牲并发效率、冻结硬件热流状态、或在logits空间设置硬性截断阈值来强行锁死确定性，其结果不仅是算力成本的指数级飙升，更是对模型高阶泛化能力与涌现特性的致命扼杀。

在复杂系统动力学中，绝对的确定性往往意味着系统失去了在高维参数空间中进行随机搜索与探索的“热力学松弛度”¹。这种松弛度，恰恰是模型表现出创造力、逻辑弹性和上下文自适应能力的物理底座。如果剥离了这种松弛度，硅基系统将从一个具备强智能涌现潜力的复杂适应系统，退化为一个机械、死板、缺乏泛化弹性的传统决定性自动机。换言之，一定程度的非确定性，不是系统的功能故障，而是硅基智能在物理时空中作为“非线性计算事件”而真实发生、流动并具备动态自适应演化能力的内禀表征。

需要明确的是，这种热力学松弛度是中性的：在创意写作、开放对话等场景中表现为探索性与创造力；在严密的数理逻辑、代码生成任务中，则可能表现为事实偏差与幻觉。这一双刃剑特征恰恰说明了对不确定性进行量化评估与场景化适配的必要性。

5.3 未来研究方向

科学的进步往往始于对控制边界的承认。未来的AI研究不应当继续执着于“在传统软件工程范式中消灭不确定性”，而应当转向“深入复杂系统内部去理解、量化并共处不确定性”，具体研究路径可拓展为以下两个方向：

第一，决策临界态的非线性动力学预测：从概率流形和动力学分叉理论出发，进一步量化不同硬件扰动源对特定激活区域的渗透率。通过识别和预测模型推理过程中的高熵决策临界态，厘清级联放大通道被触发的边界条件，从而在宏观语义层面建立不确定性的“概率气象预报”模型。

第二，基于统计物理的新型分布评估范式：超越传统软件工程中基于“单次断言、绝对对齐”的确定性评价标准。未来的评估框架应引入统计物理与复杂系统科学的工具，采用高维语义流形测度、激活特征谱分析以及基于轨迹束的拓扑相似度，在统计分布的维度上建立评测硅基智能健壮性、泛化力与创造力的全新基准。

人类与硅基智能的关系，终将从机械理性的“绝对支配与强力控制”，走向演化的理性的“深刻理解与系统共存”。接纳认知边界，不是科学的止步，而是新范式的起点。

5.4 关键假说的实证设计与可量化评估方案

本文所提出的“多层级硬件扰动”与“非线性级联放大通道”理论，虽然在复杂系统范式下具备自洽的逻辑完备性，但其科学价值的最终确立仍需建立在可量化、可证伪的实证基础之上。为了指导未来

的实证研究，本文设计了一套跨越工程层、算法层与语义层的多维度实验验证框架：

1. 硬件并发扰动与浮点误差的消融隔离实验（工程层验证）

设计两组对照实验：绝对基准对照组在单卡环境下锁死确定性内核配置、关闭动态批处理，连续运行千次以上测量输出序列的逐位重合度，剥离并发偏差后测量底层物理底噪的发生率；变量干扰实验组主动引入动态批处理、背景并发流量、跨节点分布式集群与网络抖动，观测输出非确定性发生率的变化曲线。

2. 激活空间局部雅可比矩阵谱半径的数值追踪（算法层验证）

在推理过程中主动向指定隐层注入极微弱的符号扰动向量，逐层记录扰动穿过前馈网络与层归一化前后的模长变化，计算各层局部雅可比矩阵的谱半径，定量绘制误差向量“压缩-拉伸”的动力学演化曲线，定位高敏感隐层区域。

3. 基于香农熵阈值预测选词跳变的统计验证（决策层验证）

采集大规模多轮推理的全量Logits数据，实时计算每一步的香农熵；以“是否发生Token跳变”为二分类标签，以香农熵为预测变量绘制ROC曲线并计算AUC面积，验证熵阈值作为临界态闸门的统计有效性。

4. 长时序自回归语义发散速率的拓扑度量（语义层验证）

将分叉轨迹通过冻结权重的特征提取器映射到高维语义流形空间，以自回归步数为横坐标、轨迹拓扑距离为纵坐标进行指数函数回归拟合，实际测算不同场景下类李雅普诺夫指数的经验分布。

上述方案构成了一套闭环的实证路径。通过此定量评测体系，未来的研究能够从工程底座到宏观语义进行全链路的数值卡点，从而将关于大模型非确定性的本质讨论，彻底从定性视角的假说批判，推进到具备高度物理针砭性的定量科学阶段。

附录A 概念边界说明

本文提出的“物理税”与“热力学松弛度”为启发性分析概念，为避免概念误读，特作如下边界说明：

1. 关于“物理税（Physical Tax）”

本文提出该解释视角，旨在说明大型模型推理过程中表现出的部分不可复现性，并非单纯的工程缺陷，而可能是复杂系统获得高维探索能力所伴随的系统性代价。该表述属于理论隐喻与概念化分析框架，而非已得到实验验证的确定性科学结论。不确定性与泛化能力、创造性表现、系统鲁棒性之间的具体关联机制，仍需后续研究进一步量化验证。

2. 关于“热力学松弛度（Thermodynamic Slackness）”

本文使用该术语，用于描述复杂智能系统在高维状态空间中所表现出的探索自由度与状态弹性。该术语并非统计物理学或复杂系统科学中的标准既定概念，而是本文提出的启发性描述工具，目的是为讨论非确定性与模型探索能力的关系提供统一的表述锚点。本文不声称该概念已具备严格的数学定义或完备的实验支撑。

提出上述两个概念的核心价值，在于将“非确定性与智能涌现的关联”从零散的直觉讨论转化为可标准化研究的议题，为后续相关实证与理论工作提供参照框架。

¹ 对应附录A的概念边界说明

参考文献

- [1] GOND R, KAMATH A K, RAMJEE R, et al. LLM-42: Enabling Determinism in LLM Inference with Verified Speculation[EB/OL]. (2026-01-31)[2026-06-22]. <https://arxiv.org/pdf/2601.17768.pdf>.
- [2] HORACE H. Defeating Nondeterminism in LLM Inference[EB/OL]. (2025-09-10)[2026-06-22]. <https://thinkingmachines.ai/blog/defeating-nondeterminism-in-llm-inference/>.
- [3] ZHENG Y, LIU X, WANG Z, et al. Deterministic Inference Across Tensor Parallel Sizes That Eliminates Training-Inference Mismatch[EB/OL]. (2025-11-27)[2026-06-22]. <https://arxiv.org/pdf/2511.17826v1.pdf>.
- [4] GOLDBERG D. What Every Computer Scientist Should Know About Floating-Point Arithmetic[J]. ACM Computing Surveys, 1991, 23(1): 5-48.
- [5] CALHOUN B H, CHANDRAKASAN A. On analyzing and mitigating SRAM BER due to random thermal noise[C]//2013 IEEE Computer Society Annual Symposium on VLSI (ISVLSI). IEEE, 2013: 12-17.
- [6] 郑鑫, 江竹轩, 罗志君. 软失效的原理和应对方案的研究[J]. 电子技术与软件工程, 2018(12): 98-99.
- [7] YANG G, SCHOENHOLZ S S. Mean Field Residual Networks: On the Implicit Regularization of Depth[EB/OL]. (2017-12-05)[2026-06-22]. <https://arxiv.org/pdf/1712.01731.pdf>.
- [8] ZHU Y, CHEN M, COWSIK A, et al. Subcritical Signal Propagation at Initialization in Normalization-Free Transformers[EB/OL]. (2026-04-17)[2026-06-22]. <https://arxiv.org/pdf/2604.11890.pdf>.
- [9] SHANNON C E. A Mathematical Theory of Communication[J]. Bell System Technical Journal, 1948, 27(3): 379-423.
- [10] ANDERSON P W. More is Different[J]. Science, 1972, 177(4047): 393-396.
- [11] HOLLAND J H. Emergence: From Chaos to Order[M]. Reading: Addison-Wesley, 1998.

[12] KUHN T S. The Structure of Scientific Revolutions[M]. Chicago: University of Chicago Press, 1962.

（注：文档部分内容可能由 AI 生成）